

Модель мира и VLM-оценка текстовой цели для управления агентом в среде MiniWorld

Отчёт по проекту

1. Введение

Классическая постановка обучения с подкреплением опирается на функцию награды, и для каждой новой задачи её приходится проектировать вручную. На практике именно проектирование награды часто оказывается самым трудоёмким этапом, а именно неудачно заданная награда порождает нежелательное поведение, а на переформулировку задачи уходит время. Альтернатива состоит в том, чтобы описывать цель на естественном языке и получать оценку прогресса от предобученной модели «изображение-текст» (VLM). Такие модели, обученные на сотнях миллионов пар «картинка-подпись», например CLIP [1], переносят знание из интернет-масштабных данных и не требуют ни одного примера награды из самой среды. Работоспособность этой идеи в разных вариантах уже показана в MineDojo видеоязыковая модель служит наградой для агентов в Minecraft [2], а в CLIP-подобные модели напрямую используются как zero-shot reward-модели для задач управления [3].

Вторая составляющая системы – модель мира. Вместо того чтобы проверять варианты действий в самой среде, агент может прокручивать их последствия в выученной модели динамики [4]. Рекуррентная модель с латентным состоянием (RSSM), предложенная в PlaNet [5] и развитая в Dreamer [6], делает такие воображаемые прогоны дешёвыми: вся динамика разворачивается в компактном латентном пространстве, а в пиксели декодируются только те кадры, которые нужно оценить.

В настоящей работе обе идеи соединены в минимальную работающую систему: обучена RSSM-модель мира на кадрах среды MiniWorld; поверх неё реализован MPC-планировщик, который оценивает воображаемые будущие кадры предобученным CLIP относительно текстовой цели «a large red box close up»; проведено количественное сравнение с двумя обязательными базовыми методами (случайная политика и тот же планировщик, но с выученной головой награды вместо VLM) по протоколу 3 сида на 15 эпизодов; выполнена абляция по горизонту планирования. Отдельно описан отрицательный результат:

первоначально проект строился на среде MiniGrid, однако пиксельный анализ показал, что в её топ-даун рендере отсутствует визуальный признак близости к цели, из-за чего никакая VLM-оценка там не имеет опоры; это и стало причиной перехода в MiniWorld.

2. Метод

2.1. Общая схема

Схема системы приведена на рис. 1. На каждом шаге агент получает кадр из среды и корректирует своё латентное представление о состоянии мира (posterior-фильтрация). Затем планировщик сэмплирует $N = 150$ случайных последовательностей действий длины $H = 10$ и «прокатывает» каждую в воображении – по prior-переходам модели мира, без обращения к среде. Последние $K = 3$ состояния каждого rollout-а декодируются в кадры, и CLIP превращает их в скалярную оценку соответствия текстовой цели. Выполняется первое действие лучшей последовательности, после чего цикл повторяется – это и есть управление по принципу model predictive control; такой перебор случайных кандидатов – стандартный приём model-based RL [7].

Подчеркну один момент, что VLM оценивает **будущие воображаемые кадры**, а не текущее наблюдение. Планировщику нужен ответ на вопрос «что будет, если выполнить эту последовательность действий», и оценка текущего кадра ему ничего не даёт.




Рисунок 1 — Схема системы: цикл «фильтрация → воображение → декодирование → VLM-оценка → первое действие»

2.2. Среда

Использована среда MiniWorld-OneRoomS6Fast-v0 из пакета MiniWorld [8]: комната размером 6×6 условных единиц, в которой случайно размещаются агент и красный ящик – цель. Наблюдение – вид от первого лица $60 \times 80 \times 3$ (для

модели мира сжимается до 64×64); действий три: повороты на $\pm 45^\circ$ и шаг вперёд на 0,7 ед. Эпизод считается успешным, когда агент вплотную подходит к ящику. Пример наблюдения показан на рис. 2. На этапе оценки длина эпизода ограничена 15 шагами: при таком лимите случайная политика успешна примерно в 42 % эпизодов, то есть является информативным нижним уровнем, а не «проходит всё» простым перебором. Причины, по которым вместо MiniGrid выбран MiniWorld, подробно разобраны в разд. 4.1.




Рисунок 2 — Пример наблюдения агента: красный ящик (цель) в поле зрения

2.3. Модель мира (RSSM)

Модель мира реализована по схеме RSSM [5, 6]. Состояние состоит из двух частей: детерминированной памяти h (ячейка GRU размерности 128) и стохастической компоненты z (16-мерный диагональный гауссиан). Переход имеет два режима: $\text{prior } p(z | h)$ предсказывает следующее состояние без наблюдения — именно им пользуется воображение при планировании, а $\text{posterior } q(z | h, e)$ корректирует предсказание по эмбедингу реального кадра и используется при обучении и при слежении за средой. Свёрточный энкодер из четырёх слоёв сжимает кадр 64×64 в вектор размерности 1024; транспонированный свёрточный декодер восстанавливает кадр из состояния; небольшая голова награды (два линейных слоя с ELU) предсказывает награду и нужна только для базового метода без VLM.

Функция потерь — сумма трёх слагаемых: среднеквадратичная ошибка реконструкции кадра, KL-расхождение между posterior и prior с порогом $\text{free nats}=3$ (порог не даёт этому слагаемому схлопнуться и выключить стохастическую часть) и ошибка предсказания награды. Обучающие данные —

300 эпизодов случайной политики (всего N переходов). Существенная особенность этих данных заключается в маленькой комнате случайная политика доходит до ящика примерно в половине эпизодов, поэтому у головы награды есть положительные примеры.

Обучение: 3000 шагов, батч из 32 окон по 15 кадров, оптимизатор Adam с шагом 0,001, ограничение нормы градиента 100. На GPU T4 (Google Colab) обучение заняло примерно 400 секунд. Ошибка реконструкции упала с ~ 77 до $\sim 6-7$ и вышла на плато (рис. 3), KL держался в районе 3,3–3,5.




Рисунок 3 — Ошибка реконструкции в ходе обучения модели мира

2.4. VLM-скорер

В качестве VLM использован CLIP ViT-B-16 с весами OpenAI [1]. Отметим техническую деталь: эти веса обучались с активацией QuickGELU, и их загрузка в конфигурацию с обычным GELU даёт молчаливое несогласование, о котором библиотека предупреждает; в работе используется корректный вариант ViT-B-16-quickgelu.

Оценка кадра построена контрастно: вычисляются косинусные близости эмбединга кадра к двум текстам – цели «a large red box close up» и негативу «a small red box far away», после чего берётся softmax; результат – вероятность в диапазоне $[0, 1]$, устойчивее «голой» близости к одному тексту. Оценка кандидата в планировщике – максимум сора по последним $K=3$ декодированным кадрам rollout-a.

Перед подключением скорера к планировщику я измерял, есть ли в его выходе полезный сигнал. На специально отрендеренных кадрах (агент лицом к ящику на дистанциях 4,0; 3,0; 2,0; 1,5 ед. плюс кадры, где ящик не в поле

зрения) считалась корреляция между дистанцией и скором. Для выбранной пары она составила 0,946, то есть чем ближе ящик, тем выше оценка. Скорер не допускался к планированию, пока сигнал не подтверждён измерением.

2.5. Планировщик и базовые методы

Планировщик – random shooting MPC, на каждом шаге среды сэмпляются 150 случайных последовательностей действий длины 10, все прокатываются в воображении параллельно (одним батчем), оценивается целевая функция, выполняется первое действие лучшей последовательности, затем перепланирование. Метод СЕМ сознательно не реализован: в задании он отмечен как желательное улучшение, а не требование, и вынесен в направления развития.

Сравниваются три метода, различающиеся только целевой функцией планировщика: (а) random – случайные действия без модели; (б) world-model planning без VLM – сумма предсказанной головой награды по горизонту; (в) world-model planning и VLM – CLIP-скор воображаемых кадров. Важно, что методы (б) и (в) используют один и тот же планировщик и одну и ту же модель мира, поэтому их сравнение изолирует именно вклад целевой функции.

3. Эксперименты и результаты

3.1. Протокол

Каждый метод оценивался на 3 сидах по 15 эпизодов (45 эпизодов на метод) с лимитом 15 шагов на эпизод; метрика – доля успешных эпизодов (success rate). Сиды эпизодов фиксированы и одинаковы для всех методов. Эпизод с данным сидом стартует из одной и той же конфигурации среды независимо от метода.

3.2. Основной результат

Таблица 1 – success rate трёх методов (среднее и стандартное отклонение по 3 сидам, 15 эпизодов на сид, лимит 15 шагов)

Метод	Success rate	Ст. откл. по сидам
random	0,422	0,031
world-model planning (без VLM)	0,711	0,031
world-model planning + VLM	0,578	0,113

Из табл. 1 и рис. 4 следуют три вывода. Во-первых, оба планировщика заметно превосходят случайную политику – модель мира выучила динамику

среды, а планирование в воображении работоспособно. Во-вторых, VLM-вариант достигает 0,578, не используя ни одной награды среды: цель задавалась только текстовой фразой. Это главный качественный результат работы. В-третьих, VLM-вариант уступает планировщику с головой награды и имеет втрое больший разброс по сидам; причины этого разбираются ниже.




Рисунок 4 – Success rate трёх методов

3.3. Качество модели мира

Реконструкции (рис. 5) показывают, что модель уверенно восстанавливает геометрию комнаты, шахматный пол и красный ящик. Красный ящик – это единственный объект, который обязан существовать до CLIP-оценки. Воображаемый rollout (рис. 6) выявляет ограничение. На шагах +1/+2 ящик присутствует, но уже к +4 кадры расплываются – накопление ошибки предсказания без коррекции наблюдениями. Отсюда возникает гипотеза: дальность, на которой VLM способен осмысленно оценивать будущее, ограничена не горизонтом планирования, а точностью декодированных кадров.

Верх — реальные кадры, низ — реконструкция




Рисунок 5 – Реконструкции: сверху реальные кадры, снизу –
восстановленные моделью




Рисунок 6 – Воображаемый rollout

3.4. Абляция по горизонту планирования

Гипотезу проверял прямым экспериментом: горизонт N уменьшен с 10 до 5 при прочих равных (тот же чекпоинт модели, те же сиды оценки). Результаты представлены в табл. 2 и на рис. 7.

Таблица 2 – Влияние горизонта планирования

Метод	$N = 10$	$N = 5$
planning (без VLM)	$0,711 \pm 0,031$	$0,667 \pm 0,054$
planning + VLM	$0,578 \pm 0,113$	$0,578 \pm 0,191$

Планировщик с головой награды на коротком горизонте просел ($0,711 - 0,667$), и это ожидаемо: его сигнал разрежен – награда появляется в воображении, только если кандидат успевает дотянуться до цели, а пяти шагов по 0,7 ед. из дальнего угла комнаты 6×6 для этого не хватает. VLM-вариант, напротив, не изменился вовсе: средние при $N=5$ и $N=10$ совпали до третьего знака. При $K=3$ в обоих случаях оцениваются кадры, лежащие за «точкой распывания» воображения, поэтому удлинение горизонта ничего не добавляет. Так гипотеза из разд. 3.3 превратилась в измеренный факт: ограничитель VLM-планировщика – точность воображения, а не горизонт. С этим же согласуется большой разброс VLM по сидам ($0,11-0,19$): исход эпизода во многом определяется тем, виден ли ящик в первые шаги.




Рисунок 7 – Абляция по горизонту

3.5. Качественные примеры

Записи эпизодов (GIF) доступны в репозитории в каталоге results/gifs. На выбранных для записи сидах успешные эпизоды оказались короткими: агент стартовал рядом с целью и достигал её за один шаг. Показателен финальный кадр такого эпизода (рис. 8, справа): ящик в нём уже не виден – при контакте цель уходит ниже поля зрения камеры; этот эффект отдельно обсуждается в разд. 4.4. Длинные записи, напротив, оказались неудачами: агент упирался в стену (рис. 8, слева), и весь кадр занимает однородная серая текстура, на которой ни целевой, ни негативный промпт не дают полезного градиента – планировщику не за что «зацепиться», и он подолгу остаётся на месте.




Рисунок 8 – Качественные примеры: слева представлен неудачный эпизод (агент у стены, кадр без градиента для VLM), а справа – финальный кадр успешного эпизода, но цель уже ушла ниже поля зрения

4. Обсуждение: причины отказов

4.1. Отрицательный результат. VLM-оценка в MiniGrid

Первоначально проект строился на MiniGrid – на среде, которую предлагали как пример в задании. Пайплайн CLIP при этом был полностью исправлен: на контрольной паре из чистого красного и чистого зелёного квадратов вероятность текста «a photo of a red square» составила 0,998 против 0,003. Однако сигнал цели извлечь не удалось: лучшая корреляция «дистанция до цели – скор» по восьми парам промптов составила лишь 0,108 при текстовой оценке и 0,072 при оценке похожестью на эталонный кадр «агент на цели» (image-goal).

Пиксельный анализ объяснил причину. В топ-даун рендере доля пикселей цели постоянна – 2,8 % кадра на любой дистанции: клетка не увеличивается при приближении агента, то есть в изображении отсутствует признак прогресса как таковой. Эгоцентрический вид MiniGrid ситуацию не спасает: цель занимает 2 % кадра, когда агент смотрит на неё, и 0 %, когда стоит на ней – агент закрывает её собой. Дополнительно вредит окклюзия и в топ-даун виде, стоящий на цели агент закрывает около четверти её пикселей, из-за чего кадр «на цели» выглядит для CLIP менее «зелёным», чем кадр «далеко», и знак сигнала переворачивается.

4.2. Пойманная ошибка нормализации

На одном из этапов из препроцессинга выпало деление на 255, и CLIP получал входы в диапазоне [75, 255] вместо ожидаемого [0, 1]. Примечательно, что на таких повреждённых входах диагностика показывала хороший такой разрыв между кадрами «на цели» и «далеко» (0,647 против 0,405), который после исправления полностью исчез (0,486 против 0,489): кажущийся сигнал был артефактом сломанных данных. Можно сказать, что численная проверка сигнала скорера обязательна перед любыми выводами, а правдоподобные числа на неverified пайплайне не значат ничего. Именно после этого случая диагностика была закреплена как обязательный этап перед подключением скорера к планировщику.

4.3. Точность воображения

Если учитывать все вышеперечисленные наблюдения, то следовательно VLM-планировщик фактически видит будущее на два-три шага – дальше декодер не рисует мелкий или удалённый ящик, и оценивать становится

нечего. Отсюда же высокая дисперсия по сидам, то есть там, где ящик попадает в поле зрения в первые шаги, метод работает хорошо, а там, где требуется дальний поиск – он деградирует к случайному.

4.4. Окклюзия

В MiniWorld при подходе вплотную (менее ~ 1 ед.) ящик уходит ниже поля зрения камеры, и доля его пикселей падает до нуля. Успешный финальный кадр парадоксальным образом не содержит цели (рис. 8, справа). Проблему смягчают агрегация максимумом по K кадрам и то, что успех в среде срабатывает по близости раньше, чем ящик полностью исчезает. Тем не менее это отдельный класс проблем, который стоит учитывать при выборе сред и формулировок цели для VLM-оценки.

4.5. Оговорка о сравнении с головой награды

Сильный результат базового метода с головой награды не следует обобщать. Случайная политика в маленькой комнате доходит до цели примерно в половине эпизодов сбора, обеспечивая голове награды плотный обучающий сигнал. В средах, где случайная политика практически не достигает цели (большие карты, редкая награда), голова награды остаётся без положительных примеров и слепнет, тогда как VLM не требует ни одного успешного эпизода. Корректная формулировка моего результата звучит так: VLM-оценка оказалась сопоставима с обучением на наградах даже в условиях, максимально благоприятных для последнего.

5. Направления развития

Обнаруженные ограничения прямо подсказывают дальнейшие шаги. Наиболее перспективным видится скоринг в латентном пространстве. Имеется в виду обучить небольшую голову, предсказывающую CLIP-эмбединг кадра непосредственно из латентного состояния, а это в свою очередь убирает декодер из контура оценки. Более прямолинейный путь к той же цели – это увеличить ёмкость декодера и длительность обучения, отодвинув точку расплывания воображения. Целевую функцию можно уточнить, оценивая все кадры горизонта с дисконтом, что поощряет достижение цели раньше. Планировщик, естественно, усиливается заменой random shooting на CEM [7], а следующий шаг за MPC – полноценный актор-критик в духе Dreamer [6], обучающий политику в воображении и снимающий необходимость перебора

на каждом шаге. Наконец, интересно проверить более сильные VLM (ViT-L, SigLIP) и многоцелевые текстовые формулировки.

6. Заключение

Соединение выученной модели мира и предобученной VLM позволяет управлять агентом по текстовой цели без использования наград среды: доля успешных эпизодов составила 0,578 против 0,422 у случайной политики. В работе измерены и два ограничения подхода. Первое относится к среде: для VLM-оценки в изображении должен существовать визуальный признак прогресса — его отсутствие в топ-даун рендере MiniGrid делает подход неприменимым там в принципе. Второе относится к системе: узким местом оказалась точность воображения, а не горизонт планирования, — вывод, подтверждённый абляцией. Оба ограничения указывают конкретные направления развития, сформулированные выше.

СПИСОК ЛИТЕРАТУРЫ

1. Radford A., Kim J. W., Hallacy C. [и др.] Learning Transferable Visual Models From Natural Language Supervision // Proceedings of the 38th International Conference on Machine Learning (ICML). — 2021. — URL: <https://arxiv.org/abs/2103.00020>
2. Fan L., Wang G., Jiang Y. [и др.] MineDojo: Building Open-Ended Embodied Agents with Internet-Scale Knowledge // Advances in Neural Information Processing Systems 35 (NeurIPS). — 2022. — URL: <https://arxiv.org/abs/2206.08853>
3. Rocamonde J., Montesinos V., Nava E., Perez E., Lindner D. Vision-Language Models are Zero-Shot Reward Models for Reinforcement Learning // International Conference on Learning Representations (ICLR). — 2024. — URL: <https://arxiv.org/abs/2310.12921>
4. Ha D., Schmidhuber J. Recurrent World Models Facilitate Policy Evolution // Advances in Neural Information Processing Systems 31 (NeurIPS). — 2018. — URL: <https://arxiv.org/abs/1809.01999>
5. Hafner D., Lillicrap T., Fischer I. [и др.] Learning Latent Dynamics for Planning from Pixels // Proceedings of the 36th International Conference on Machine Learning (ICML). — 2019. — URL: <https://arxiv.org/abs/1811.04551>
6. Hafner D., Lillicrap T., Ba J., Norouzi M. Dream to Control: Learning Behaviors by Latent Imagination // International Conference on Learning Representations (ICLR). — 2020. — URL: <https://arxiv.org/abs/1912.01603>
7. Chua K., Calandra R., McAllister R., Levine S. Deep Reinforcement Learning in a Handful of Trials using Probabilistic Dynamics Models // Advances in Neural Information Processing Systems 31 (NeurIPS). — 2018. — URL: <https://arxiv.org/abs/1805.12114>
8. Chevalier-Boisvert M., Dai B., Towers M. [и др.] Minigrid & Miniworld: Modular & Customizable Reinforcement Learning Environments for Goal-Oriented Tasks // Advances in Neural Information Processing Systems 36 (NeurIPS). — 2023. — URL: <https://arxiv.org/abs/2306.13831>